Kết quả so sánh trên dataset POJ-104

Baseline MOSS và ba mô hình M1 – M3

Nhóm nghiên cứu

1 Việc cần làm và dữ liệu

Bài toán: cho hai hàm code, có phải là bản sao của nhau hay không. Dùng dataset POJ-104, gồm 51.991 hàm C++. Ghép thành 66.000 cặp, mỗi cặp có nhãn "bản sao" hay "không bản sao". Chia ba phần: train 45.000 cặp, validation 10.000, test 11.000. Tập test cân bằng, có 5.500 cặp dương và 5.500 cặp âm.

Ngưỡng quyết định của mọi mô hình được chọn trên *validation* rồi giữ nguyên, không tinh chỉnh lại trên test.

2 Các mô hình

- **B0 – MOSS.** Thuật toán Winnowing của Sleator & Bernstein (2003), cài lại chạy cục bộ. Đây là baseline.
- **M1 – CodeBERT.** Mô hình ngôn ngữ cheo token, fine-tune để so hai hàm.
- **M2 – GraphCodeBERT.** Giống M1 nhưng có thêm thông tin cấu trúc (quan hệ cây cú pháp, dữ liệu luồng) nối các token.
- **M3 – ASTNN.** Rút cây cú pháp thành đồ thị, đưa qua mạng nơ-ron đệ quy để tạo vector đặc trưng. Không dùng token thô.

3 Kết quả trên tập test

Cột F1 ghi dạng `mean ± SD`. Ý nghĩa: lấy tập test hiện có, bốc ngẫu nhiên lại 2.000 lần, tính F1 mỗi lần, rồi lấy trung bình và độ lệch chuẩn.

Mô hình	Precision	Recall	F1	ROC-AUC
B0 – MOSS	0.646	0.722	0.682 ± 0.005	0.731
M1 – CodeBERT	0.931	0.890	0.910 ± 0.003	0.973
M2 – GraphCodeBERT	0.883	0.933	0.907 ± 0.003	0.971
M3 – ASTNN	0.641	0.903	0.750 ± 0.004	0.795

Vài điều đọc được từ bảng:

- M1 và M2 gần như ngang nhau. Chênh lệch F1 chỉ 0.003, nhỏ hơn cả độ lệch chuẩn. Thêm thông tin cấu trúc của M2 không giúp ở bài toán này.
- M1 thiên về precision, M2 thiên về recall. M1 bỏ sót nhiều cặp bản sao hơn, M2 đoán nhầm nhiều cặp không phải bản sao hơn.
- MOSS kém hơn M1 khá xa (F1 0.682 so với 0.910). Lý do dễ hiểu: MOSS so các đoạn chữ giống hệt từng ký tự, mà trong POJ-104 hai hàm là bản sao thì tên biến và cấu trúc đã bị đổi khá nhiều.
- M3 nhớ nhiều bản sao (recall 0.903) nhưng hay đoán nhầm (precision 0.641).

4 M1 và M2 có thật sự khác nhau không?

Không thể trả lời bằng cách nhìn hai cột ± SD rồi kết luận, vì SD ở đây đo độ lớn của tập test chứ không đo sai khác giữa hai mô hình. Cách đúng là so hai mô hình trên *cùng một* tập test.

Cặp so sánh	ΔF1	Khoảng tin cậy 95%	McNemar
M1 – M2	-0.003	$[-0.0085,\ +0.0028]$	$p = 0.013$
M1 – B0	$+0.228$	$[+0.2175,\ +0.2388]$	$p < 10^{-300}$
M1 – M3	$+0.160$	$[+0.1507,\ +0.1688]$	$p < 10^{-300}$

Hai cột cuối lại không thống nhất, và điều đó có nghĩa:

- Khoảng tin cậy của ΔF1 *chứa* 0, nên không đủ bằng chứng để nói M1 khác M2 về F1.
- McNemar lại ra $p = 0.013$: hai mô hình *có* khác nhau về số cặp dự đoán đúng.
- Hai kết quả này không mâu thuẫn. Chúng khác nhau vì đo hai thứ khác nhau: McNemar hỏi "tổng số dự đoán đúng có khác không", còn khoảng tin cậy hỏi "F1 có khác không". M1 và M2 sai ở *hướng khác nhau* (M1 hơi thiên precision, M2 thiên recall) nên trong F1 hai sai lệch đó gần như triệt tiêu.

Kết luận đúng nhất là: **M1 và M2 không phân biệt được về F1**. Chọn cái nào cũng được về mặt F1; nếu cần recall cao thì chọn M2.

Với MOSS và M3 thì khoảng tin cậy không chứa 0, tức là khác biệt thật, không phải nhiễu.

5 Hạn chế cần nói rõ

- Mỗi mô hình mới chạy *một lần*, nên chưa có độ lệch chuẩn do biến thiên giữa các lần train. Muốn có con số đó thì phải train lại vài seed; với M1/M2 mỗi lần mất khoảng 7 giờ GPU. Hiện tại ± SD trong bảng chỉ phản ánh độ lớn của tập test.
- M2 vẫn đang train dở (3 epoch, F1 trên validation còn đang tăng), nên số 0.907 này có thể còn tăng nữa.
- M1 và M2 bị cắt còn 256 token. Hàm POJ-104 trung bình dài hơn thế, nên phần đuôi hàm bị mất.
- M3 có thể chưa train tới đủ. Số của M3 nên xem là tạm.

6 Đang làm tiếp

M4 (CPG-GNN) đang xây dựng: cần dựng code property graph bằng Joern trên Kaggle trước, nên hiện chưa có kết quả. Sau khi M1 – M3 chốt xong sẽ cho M4 chạy và so thêm vào bảng này.