Báo cáo kết quả huấn luyện

Đề tài: Phát hiện trùng lặp code

Ngày báo cáo: 03/10/2026

Tổng quan

- Bài toán: phát hiện trùng lặp code trên tập dữ liệu POJ-104.
- Nội dung: kết quả huấn luyện các phương pháp trên tập dữ liệu POJ-104.

Dữ liệu

- 51.991 hàm C++, 66.000 cặp, chia ba phần không trùng cặp.
- Ngưỡng quyết định chọn trên validation, giữ nguyên khi test.

Phần	Số cặp	Cặp dương	Dùng để
Train	45.000	22.500	huấn luyện
Validation	10.000	5.000	chọn ngưỡng quyết định
Test	11.000	5.500	báo cáo kết quả cuối

Các phương pháp

- **MOSS** (baseline). Sleator & Bernstein 2003. So khớp đặc trưng k-gram. Tham số k=20, w=5.
- **CodeBERT**. `microsoft/codebert-base`. Ghép ba vector (A, B, độ lệch tuyệt đối A với B) rồi qua một lớp MLP.
- **GraphCodeBERT**. `microsoft/graphcodebert-base`. Như CodeBERT, thêm quan hệ token qua cây cú pháp và dữ liệu luồng. Giữ nguyên siêu tham số CodeBERT.
- **ASTNN**. Câu cú pháp rút gọn thành đồ thị câu lệnh, qua mạng đệ quy và mạng hai chiều. Huấn luyện từ đầu.
- **CPG-GNN**. Đồ thị thuộc tính dạng code property graph (6 loại cạnh), qua mạng GAT 3 tầng rồi đầu MLP như ba phương pháp trên. Huấn luyện từ đầu.

Cấu hình huấn luyện

- Kaggle GPU Tesla T4, seed 42. Số epoch: CodeBERT 3, GraphCodeBERT 3, ASTNN 7, CPG-GNN 5.
- MOSS: không huấn luyện.

Cấu hình	CodeBERT	GraphCodeBERT	ASTNN	CPG-GNN
Mô hình có sẵn	codebert-base	graphcodebert-base	không, từ đầu	không, từ đầu
Độ dài đầu vào	256 token	256 token	không cắt	tối đa 1500 node
Learning rate	2e-5	2e-5	1e-3	1e-3
Batch size	16	16	32	16
Số tham số	126.416.641	126.416.641	428.001	203.649
Thời gian	7,0 giờ	6,9 giờ	40 phút	57 phút

Quá trình huấn luyện

Phương pháp	1	2	3	Thời gian	Đánh giá
CodeBERT	**0,9191**	**0,9191**	0,9116	7,0 h	đã quá tay
GraphCodeBERT	**0,9155**	0,9138	0,9108	6,9 h	đã quá tay
ASTNN	0,7890	0,8141	0,8414	40 phút	tốt nhất **0,8530** ở epoch 4; dừng epoch 7
CPG-GNN	0,7798	0,7955	0,8004	57 phút	tốt nhất **0,8194** ở epoch 5; còn tăng

Kết quả

- Tập test, 11.000 cặp.
- Dấu ±: độ lệch chuẩn, bốc ngẫu nhiên lại tập test 2.000 lần.

Phương pháp	Precision	Recall	F1	ROC-AUC	Cặp đoán nhầm
MOSS	0,646	0,722	0,682 ± 0,005	0,731	2.177
CodeBERT	0,931	0,890	0,910 ± 0,003	0,973	363
GraphCodeBERT	0,883	0,933	0,907 ± 0,003	0,971	682
ASTNN	0,760	0,894	0,822 ± 0,004	0,889	2.138
CPG-GNN	0,695	0,885	0,779 ± 0,004	0,864	2.768

Hạn chế

- Mỗi phương pháp chạy một lần với seed 42.
- ASTNN dừng ở epoch 7 (early stopping, tốt nhất epoch 4).
- CPG-GNN dừng ở epoch 5 (hết epoch, val F1 còn tăng).
- CodeBERT, GraphCodeBERT cắt hàm còn 256 token; 78,6% hàm trong tập train bị cắt.

Kế hoạch tiếp theo

- Chạy lại CodeBERT, GraphCodeBERT vài seed.
- Thử độ dài đầu vào 512 token.