Báo cáo kết quả huấn luyện & Thử nghiệm

Đề tài: Phát hiện trùng lặp mã nguồn C/C++ và Python

Ngày 12 tháng 10 năm 2026

1 Kết quả tuần này

Hoàn thành train 5 phương pháp trên POJ-104: CodeBERT (`codebert-base`, 3 epoch), GraphCodeBERT (`graphcodebert-base`, 3 epoch), ASTNN (7 epoch), CPG-GNN (15 epoch), Hybrid (warm-start từ GraphCodeBERT và CPG-GNN, fine-tune 4 epoch). Ngưỡng chọn trên validation, giữ nguyên khi test và khi demo. Chạy demo cho kết quả trên tập test ở mục 6.

Ngày 12-10 chạy thêm M1-512 và M2-512 (warm-start từ checkpoint 256, `max_length` 512, effective batch 32 giữ nguyên, 2 epoch do hết budget 9h): test F1 0,941 và 0,955, đều vượt bản 256 (0,910 và 0,907). Chi tiết ở mục 2b và 3b.

2 Kết quả huấn luyện

Val F1 theo epoch (ngưỡng chọn trên validation).

Epoch	M3	M4	M1-256	M2-256	M1-512	M2-512	M5
E0	0,789	0,782	0,919	**0,915**	**0,921**	0,932	**0,914**
E1	0,814	0,773	**0,919**	0,914	0,918	**0,933**	0,893
E2	0,841	0,806	0,912	0,911	—	—	0,859
E3	**0,853**	0,794	—	—	—	—	0,879
E4	0,804	0,833	—	—	—	—	—
E5	0,823	0,816	—	—	—	—	—
E6	0,841	0,804	—	—	—	—	—
E7	—	0,817	—	—	—	—	—
E8	—	0,816	—	—	—	—	—
E9	—	0,836	—	—	—	—	—
E10	—	0,827	—	—	—	—	—
E11	—	0,830	—	—	—	—	—
E12	—	0,837	—	—	—	—	—
E13	—	0,838	—	—	—	—	—
E14	—	**0,842**	—	—	—	—	—

M1 = CodeBERT, M2 = GraphCodeBERT, M3 = ASTNN, M4 = CPG-GNN, M5 = Hybrid. Cột 512 warm-start từ checkpoint 256 (12-10, T4, hết budget 9h nên dừng ở 2 epoch). Nguồn: `training_history.csv` trong `results/exp00{2,3}_*_512/`.

3 Kết quả test

PP	Prec.	Rec.	F1	AUC	Ngưỡng
M3	0,760	0,894	0,821	0,889	0,557
M4	0,723	0,887	0,797	0,882	0,470
M1-256	0,931	0,890	0,910	0,973	0,590
M2-256	0,883	0,933	0,907	0,971	0,430
M1-512	0,947	0,935	**0,941**	**0,987**	0,210
M2-512	0,951	0,959	**0,955**	**0,991**	0,660
M5	0,905	0,922	**0,913**	0,970	0,370

3.1 So sánh 256 với 512 token

M1: F1 0,910 → **0,941** (+0,031); FP 363 → 288, FN 606 → 357; val F1 0,920 → 0,924 (ngưỡng 0,21). M2: F1 0,907 → **0,955** (+0,048); FP 682 → 269, FN 371 → 228; val F1 0,916 → 0,934 (ngưỡng 0,66). Tỉ lệ code bị cắt giảm từ 78,6% (train) / 73,5% (val) xuống còn 25,5% / 22,3%, đúng vùng lỗi FN tập trung ở code dài nên recall tăng mạnh nhất (M1 0,890 → 0,935; M2 0,933 → 0,959). Cả hai bản 512 warm-start từ checkpoint 256, chỉ chạy 2 epoch (hết budget 9h trên T4: M1 best epoch 0 với val F1 0,921; M2 best epoch 1 với val F1 0,933). Nguồn số liệu: `results/exp002_codebert_poj104_512/metrics.json` và `results/exp003_graphcodebert_poj104_512/metrics.json`.

6 Minh hoạ

Cách đọc hình:

- Hai phía cùng màu là hai đoạn chính mô hình đó cho là khớp nhau.
- Mỗi mô hình một bảng màu riêng vì mỗi họ nhìn code bằng tín hiệu riêng.
- CodeBERT, GraphCodeBERT, Hybrid bắt cặp từng từ trên vector encoder.
- ASTNN bắt cặp câu lệnh trên vector RvNN, bỏ span bao hơn 60% file và chỉ giữ statement trong cùng (không bôi cả hàm).
- CPG-GNN bắt cặp dòng trên vector node GAT.
- MOSS tô đúng vùng khớp mà server Stanford trả về trên trang match (cặp không được gắn cờ hiện trắng trơn, không có màu nào).
- Vàng lẻ là token mô hình dựa vào để cho điểm nhưng không ghép được cặp, không màu là phần còn lại.

6.1 Cặp clone: 355523 với 355575

Hai file giống hệt nhau. Cả 5 phương pháp kết luận đúng: M1-256 1,000 / M1-512 1,000, M2-256 1,000 / M2-512 1,000, M3 0,985, M4 0,967, M5 1,000, đều trên ngưỡng nên là clone. MOSS server cũng gắn cờ đúng (0,980).

CodeBERT – 1,000 (clone)

File A (355523)

```
#include <bits/stdc++.h>
using namespace std ;
int main() {
long long a, b ;
cin>>a>> b ;
if (a >b){
cout<<"deficit"<< endl;
cout << a - b <<endl ;
}
else if (a == b ){
cout << "break-even"<< endl ;
cout << a- b ;
}
else if (a < b ){
cout<< "profit" <<endl ;
cout<<b-a;
}
return 0 ;
}
```

File B (355575)

```
#include <bits/stdc++.h>
using namespace std ;
int main() {
long long a, b ;
cin>>a>>b ;
if (a >b){
cout <<"deficit"<< endl;
cout << a - b <<endl ;
}
else if (a == b ){
cout << "break-even"<< endl ;
cout << a- b ;
}
else if (a < b ){
cout << "profit" <<endl ;
cout<<b-a;
}
return 0 ;
}
```

GraphCodeBERT – 1,000 (clone)

File A (355523)

```
#include <bits/stdc++.h>
using namespace std;
int main () {
long long a , b;
cin >> a >> b ;
if ( a > b){
cout <<"deficit"<< endl;
cout << a - b<<endl ;
}
else if ( a == b){
cout << "break-even" << endl;
cout<<a- b ;
}
else if (a< b ){
cout << "profit"<< endl ;
cout<<b-a ;
}
return 0;
}
```

File B (355575)

```
#include <bits/stdc++.h>
using namespace std;
int main () {
long long a , b;
cin >> a >> b ;
if ( a > b){
cout <<"deficit"<< endl;
cout << a - b<<endl ;
}
else if ( a == b){
cout << "break-even" << endl;
cout<<a- b ;
}
else if ( a< b ){
cout << "profit"<< endl ;
cout<<b-a ;
}
return 0;
}
```

ASTNN – 0,985 (clone)

File A (355523)

```
#include <bits/stdc++.h>
using namespace std;
int main() {
long long a,b;
cin>>a>>b;
if (a>b) {
cout<<"deficit"<<endl;
cout<<a-b<<endl;
}
else if (a==b) {
 cout <<"break-even"<<endl;
 cout<<a-b;
 }
else if (a<b){
 cout<<"profit"<<endl;
 cout<<b-a;
 }
return 0;
}
```

File B (355575)

```
#include <bits/stdc++.h>
using namespace std;
int main() {
long long a,b;
cin>>a>>b;
if (a>b) {
cout<<"deficit"<<endl;
cout<<a-b<<endl;
}
else if (a==b) {
 cout <<"break-even"<<endl;
 cout<<a-b;
 }
else if (a<b){
 cout<<"profit"<<endl;
 cout<<b-a;
 }
return 0;
}
```

CPG-GNN – 0,967 (clone)

File A (355523)

```
#include <bits/stdc++.h>
using namespace std;
int main() {
 long long a,b;
 cin>>a>>b;
 if (a>b){
cout<<"deficit"<<endl;
 cout<<a-b<<endl;
}
 else if (a==b){
 cout <<"break-even"<<endl;
 cout<<a-b;
}
 else if (a<b){
cout<<"profit"<<endl;
cout<<b-a;
}
 return 0;
}
```

File B (355575)

```
#include <bits/stdc++.h>
using namespace std;
int main() {
 long long a,b;
 cin>>a>>b;
 if (a>b){
cout<<"deficit"<<endl;
 cout<<a-b<<endl;
}
 else if (a==b){
 cout <<"break-even"<<endl;
 cout<<a-b;
}
 else if (a<b){
cout<<"profit"<<endl;
cout<<b-a;
}
 return 0;
}
```

Hybrid – 1,000 (clone)

File A (355523)

```
#include <bits/stdc++.h>
using namespace std ;
int main () {
long long a ,b;
cin>>a>>b ;
if (a > b ){
cout <<"deficit"<< endl;
cout <<a-b << endl ;
}
else if ( a == b ){
cout << "break-even"<< endl ;
cout<< a - b;
}
else if (a<b ){
cout << "profit"<< endl;
cout << b - a;
}
return 0;
}
```

File B (355575)

```
#include <bits/stdc++.h>
using namespace std ;
int main () {
long long a ,b;
cin>>a>>b ;
if (a> b ){
cout <<"deficit"<< endl;
cout <<a-b << endl ;
}
else if ( a == b ){
cout << "break-even"<< endl ;
cout<< a - b;
}
else if (a<b ){
cout << "profit"<< endl;
cout << b - a;
}
return 0;
}
```

MOSS (server Stanford) — 0,980 (clone)

File A (355523)

```
#include <bits/stdc++.h>
using namespace std;
int main() {
 long long a,b;
 cin>>a>>b;
 if (a>b){
 cout<<"deficit"<<endl;
 cout<<a-b<<endl;
 }
 else if (a==b){
 cout <<"break-even"<<endl;
 cout<<a-b;
 }
 else if (a<b){
 cout<<"profit"<<endl;
 cout<<b-a;
 }
 return 0;
}
```

File B (355575)

```
#include <bits/stdc++.h>
using namespace std;
int main() {
 long long a,b;
 cin>>a>>b;
 if (a>b){
 cout<<"deficit"<<endl;
 cout<<a-b<<endl;
 }
 else if (a==b){
 cout <<"break-even"<<endl;
 cout<<a-b;
 }
 else if (a<b){
 cout<<"profit"<<endl;
 cout<<b-a;
 }
 return 0;
}
```

6.2 Cặp không clone: bài 30 với 33

Hai bài khác nhau của POJ-104. Cả 5 phương pháp kết luận đúng: M1-256 0,000 / M1-512 0,001, M2-256 0,010 / M2-512 0,000, M3 0,178, M4 0,190, M5 0,000, đều dưới ngưỡng nên không clone. MOSS server cũng không gắn cờ (0,000) nên đúng. Điểm bản 512 chấm bằng `best_checkpoint.pt` của `exp002/exp003_poj104_512` với ngưỡng 0,21/0,66; bản 256 dùng ngưỡng 0,59/0,43 — cùng verdict, điểm số chênh do ngưỡng và trọng số khác nhau.

CodeBERT – 0,000 (không clone)

File A (bai 30)

```
int main(){
int n,sum=0;
cin>>n;
for (int i=1;i<=n;i++)
{
if(!(i%10==7)&&!(i%7==0)&&!(i/10==7)){
sum=sum+i*i;}
}
cout<<sum<<endl;
return 0;
}
```

File B (bai 33)

```
int main() {
int n,i;
 char a[9999][256],*p;
scanf("%d",&n);
for(i=0;i<n;i++){
scanf("%s",a[i]);

}
for(i=0;i<n;i++){
 for(p=a[i];*p!='\0';p++){
if(*p=='A'){*p='T';}
else if(*p=='C'){*p='G';}
else if(*p=='G'){*p='C';}
else if(*p=='T'){*p='A';}
}
}
for(i=0;i<n;i++){
puts(a[i]);}


return 0;
}
```

GraphCodeBERT – 0,010 (không clone)

File A (bai 30)

```
int main(){
int n,sum=0;
cin>>n;
 for (int i=1;i<=n;i++)
{
if(!(i%10==7)&&!(i%7==0)&&!(i/10==7)){
  sum=sum+i*i;}
}
cout<<sum<<endl;
return 0;
}
```

File B (bai 33)

```
int main() {
int n,i;
char a[9999][256],*p;
scanf("%d",&n);
 for(i=0;i<n;i++){
scanf("%s",a[i]);

}
for(i=0;i<n;i++){
for(p=a[i];*p!='\0';p++){
if(*p=='A'){*p='T';}
 else if(*p=='C'){*p='G';}
else if(*p=='G'){*p='C';}
else if(*p=='T'){*p='A';}
}
}
for(i=0;i<n;i++){
puts(a[i]);}


return 0;
}
```

ASTNN – 0,178 (không clone)

File A (bai 30)

```
int main(){
int n,sum=0;
cin>>n;
for (int i=1;i<=n;i++)
{
if(!(i%10==7)&&!(i%7==0)&&!(i/10==7)){
  sum=sum+i*i;}
}
cout<<sum<<endl;
return 0;
}
```

File B (bai 33)

```
int main() {
int n,i;
char a[9999][256],*p;
scanf("%d",&n);
for(i=0;i<n;i++){
scanf("%s",a[i]);

}
for(i=0;i<n;i++){
for(p=a[i];*p!='\0';p++){
if(*p=='A'){*p='T';}
else if(*p=='C'){*p='G';}
else if(*p=='G'){*p='C';}
else  if(*p=='T'){*p='A';}
}
}
for(i=0;i<n;i++){
puts(a[i]); }


return 0;
}
```

CPG-GNN – 0,190 (không clone)

File A (bai 30)

```
int main(){
  int n,sum=0;
  cin>>n;
  for (int i=1;i<=n;i++)
{
  if(!(i%10==7)&&!(i%7==0)&&!(i/10==7)){
  sum=sum+i*i;}
}
cout<<sum<<endl;
  return 0;
}
```

File B (bai 33)

```
int main() {
int n,i;
  char a[9999][256],*p;
scanf("%d",&n);
  for(i=0;i<n;i++){
scanf("%s",a[i]);

}
for(i=0;i<n;i++){
  for(p=a[i];*p!='\0';p++){
  if(*p=='A'){*p='T';}
else if(*p=='C'){*p='G';}
  else if(*p=='G'){*p='C';}
  else if(*p=='T'){*p='A';}
}
}
for(i=0;i<n;i++){
  puts(a[i]);}


  return 0;
}
```

Hybrid – 0,000 (không clone)

File A (bai 30)

```
int main(){
int n,sum=0;
cin>>n;
for (int i=1;i<=n;i++)
{
if(!(i%10==7)&&!(i%7==0)&&!(i/10==7)){
sum=sum+i*i;}
}
cout<<sum<<endl;
return 0;
}
```

File B (bai 33)

```
int main() {
int n,i;
char a[9999][256],*p;
scanf("%d",&n);
for(i=0;i<n;i++){
scanf("%s",a[i]);

}
for(i=0;i<n;i++){
for(p=a[i];*p!='\0';p++){
if(*p=='A'){*p='T';}
else if(*p=='C'){*p='G';}
else if(*p=='G'){*p='C';}
else if(*p=='T'){*p='A';}
}
}
for(i=0;i<n;i++){
puts(a[i]);}


return 0;
}
```

MOSS (server Stanford) — 0,000 (không clone)

File A (bai 30)

```
int main(){
int n,sum=0;
cin>>n;
for (int i=1;i<=n;i++)
{
if(!(i%10==7)&&!(i%7==0)&&!(i/10==7)){
sum=sum+i*i;}
}
cout<<sum<<endl;
return 0;
}
```

File B (bai 33)

```
int main() {
int n,i;
char a[9999][256],*p;
scanf("%d",&n);
for(i=0;i<n;i++){
scanf("%s",a[i]);

}
for(i=0;i<n;i++){
for(p=a[i];*p!='\0';p++){
if(*p=='A'){*p='T';}
else if(*p=='C'){*p='G';}
else if(*p=='G'){*p='C';}
else if(*p=='T'){*p='A';}
}
}
for(i=0;i<n;i++){
puts(a[i]);}


return 0;
}
```

7 Hạn chế

- Hybrid đỉnh ngay epoch đầu rồi overfit, CPG-GNN thì val F1 còn tăng ở epoch cuối.
- M1/M2 bản 256 cắt đầu vào 256 token (78,6% train bị cắt), CPG-GNN chặn 1500 node, hàm dài bị mất thông tin. Bản 512 đã giảm tỉ lệ cắt xuống 25,5% và F1 tăng +0,031/+0,048 (mục 3b), nhưng 1/4 code dài nhất vẫn bị cắt.

8 Kế hoạch tiếp theo

- Hybrid V2 (giảm LR) không tốt hơn V1 nên giữ V1; tiếp theo thử freeze encoder, chỉ train head rồi mới unfreeze.
- Đầu vào 512 token đã thử xong cho M1/M2 (cải thiện rõ); tiếp theo nới giới hạn node của CPG-GNN và thử Hybrid trên nền encoder 512.