Báo cáo tiến độ tuần

Đề tài: Phát hiện trùng lặp mã nguồn

Kichirou

Ngày 31 tháng 10 năm 2026

1 Tóm tắt công việc trong tuần

- Huấn luyện lại 4 phương pháp (CodeBERT, GraphCodeBERT, ASTNN, CPG-GNN) trên tập dữ liệu BigCloneBench (Java).
- Thu thập 703 bài nộp C/C++ từ hệ thống CODER HUSC và xây dựng tập kiểm thử thực tế 400 cặp theo chuẩn phân tầng BigCloneBench.
- Kiểm thử và so sánh kết quả của các mô hình trên cả tập dữ liệu Java và C/C++.

2 Tập dữ liệu BigCloneBench (Java)

Sử dụng tập dữ liệu **BigCloneBench** (thuộc bộ benchmark CodeXGLUE):

- **Nguồn dữ liệu:** Trích xuất từ kho IJaDataset-2.0, gồm các hàm Java thuộc 43 nhóm chức năng (xử lý file, mạng, database, chuỗi,...).
- **Cấu trúc mẫu:** Mỗi mẫu là một cặp hàm Java (`func1`, `func2`) kèm nhãn: 1 (Trùng lặp) hoặc 0 (Không trùng lặp).
- **Độ dài mã nguồn:** Trung bình $33,96$ dòng/hàm.

Bảng 1: Quy mô phân chia tập dữ liệu BigCloneBench

Tập dữ liệu	Số lượng cặp	Tỉ lệ Clone
Train	30.000	50% (15.000 clone : 15.000 non-clone)
Val	3.000	50% (1.500 clone : 1.500 non-clone)
Test	5.000	50% (2.500 clone : 2.500 non-clone)

3 Thông số cấu hình huấn luyện

Bảng 2: Thông số huấn luyện các mô hình

Thông số	M1 Đóng băng 12 tầng	M1 Fine-tuning toàn bộ	M2 Đóng băng 12 tầng	M2 Fine-tuning toàn bộ	M3	M4
Biểu diễn đầu vào	Chuỗi Token (≤ 256)	Chuỗi Token (≤ 256)	Chuỗi Token + DFG	Chuỗi Token + DFG	Cây cú pháp AST	Đồ thị CPG
Thuật toán tối ưu	AdamW	AdamW	AdamW	AdamW	Adam	AdamW
Tốc độ học (LR)	10^{-3}	2×10^{-5}	10^{-3}	2×10^{-5}	10^{-3}	5×10^{-4}
Kích thước Batch	64	64	64	64	32	32
Số lượng Epochs	3	5	3	5	5	5
Hàm mất mát	BCEWithLogits	BCEWithLogits	BCEWithLogits	BCEWithLogits	BCEWithLogits	BCEWithLogits

- **Chưa huấn luyện:** Dùng vector `[CLS]` từ pre-trained model nguyên bản của Microsoft và tính độ tương đồng Cosine, không qua huấn luyện.
- **Đóng băng 12 tầng:** Khóa 12 tầng Transformer của backbone, chỉ huấn luyện lớp phân loại MLP head ($1,77$M tham số).
- **Fine-tuning toàn bộ:** Mở khóa và tinh chỉnh toàn bộ $126,4$M tham số (cả backbone và head).
- **M3 (ASTNN) và M4 (CPG-GNN):** M3 mã hóa câu lệnh AST bằng RvNN + Bi-GRU; M4 xử lý nút và cạnh đồ thị qua 3 tầng GAT.

4 Kết quả kiểm thử trên tập BigCloneBench (Java)

Bảng 3: Kết quả kiểm thử các mô hình trên tập BigCloneBench Test (5.000 cặp — Tỉ lệ 1:1)

Mô hình / Phiên bản	Ngưỡng	Đúng Trùng lặp	Đúng Không TL	F1-Score	Precision	Recall	Accuracy
M1 Chưa huấn luyện	0,01	2.500 / 2.500	0 / 2.500	66,67%	50,00%	**100,00%**	50,00%
M1 Đóng băng 12 tầng	0,91	1.991 / 2.500	2.100 / 2.500	81,41%	83,27%	79,64%	81,82%
M1 Fine-tuning toàn bộ	0,88	2.234 / 2.500	2.426 / 2.500	**92,93%**	96,79%	89,36%	**93,20%**
M2 Chưa huấn luyện	0,93	2.089 / 2.500	902 / 2.500	67,53%	56,66%	83,56%	59,82%
M2 Đóng băng 12 tầng	0,10	2.189 / 2.500	2.171 / 2.500	87,25%	86,93%	87,56%	87,20%
M2 Fine-tuning toàn bộ	0,94	2.197 / 2.500	2.458 / 2.500	92,72%	**98,12%**	87,88%	93,10%
M3 Chưa huấn luyện	0,87	2.500 / 2.500	7 / 2.500	66,73%	50,07%	**100,00%**	50,14%
M3 Fine-tuning toàn bộ	0,52	2.222 / 2.500	449 / 2.500	65,61%	52,00%	88,88%	53,42%
M4 Chưa huấn luyện	0,01	2.500 / 2.500	0 / 2.500	66,67%	50,00%	**100,00%**	50,00%
M4 Fine-tuning toàn bộ	0,70	2.500 / 2.500	0 / 2.500	66,67%	50,00%	**100,00%**	50,00%

Nhận xét nhanh:

- M1 và M2 sau khi Fine-tuning toàn bộ đạt hiệu năng rất cao trên tập Test BigCloneBench, đạt F1 gần 93% và Precision lên tới $96,79\% - 98,12\%$.
- Bản Đóng băng 12 tầng của M1 và M2 đạt kết quả rất tốt (F1 $81,41\% - 87,25\%$), giữ vững được ranh giới phân loại nhờ trọng số biểu diễn gốc của Transformer.
- M3 (ASTNN) và M4 (CPG-GNN) bị giảm độ chính xác ở cặp Không trùng lặp do kích thước cây cú pháp và đồ thị của các hàm Java trong BigCloneBench rất lớn, gây khó khăn cho quá trình lan truyền gradient.

5 Kiểm thử thực tế trên dữ liệu C/C++ (Dữ liệu từ coder)

- **Dữ liệu thu thập:** 703 bài nộp đạt AC từ 8 bài toán khác nhau (`spit0019`, `spit0060`, `spit0062`, `spit0067`, `spit0070`, `spit0090`, `spit0100`, `spit0108`).
- **Cách tạo cặp kiểm thử theo chuẩn BigCloneBench (Svajlenko & Roy) [1]:**
  - *Tiền xử lý:* Dùng `CppLexer` xóa comment, khoảng trắng; chuẩn hóa tên biến/hàm thành `ID`, hằng số thành `NUM`, chuỗi thành `STR`.
  - *Đo độ tương đồng cú pháp:*

$$\text{Sim}(f_1, f_2) = \min\left(\frac{|T_1 \cap T_2|}{|T_1|}, \frac{|T_1 \cap T_2|}{|T_2|}\right)$$

  - *Gán nhãn cặp kiểm thử (tổng cộng 400 cặp):*
    - **Không trùng lặp (Nhãn 0 — 200 cặp):** Ghép 2 bài thuộc 2 bài toán khác nhau (khác biệt hoàn toàn về thuật toán và I/O).
    - **Trùng lặp (Nhãn 1 — 200 cặp):** Ghép 2 bài cùng giải 1 bài toán (cùng AC), chia thành:
      - *Sao chép cú pháp (Type-1/2/ST3):* $\text{Sim} \geq 70\%$ (50 cặp) — Code giống nhau nhiều, chỉ đổi tên biến hoặc dùng chung template.
      - *Tương đồng vừa (MT3):* $50\% \leq \text{Sim} < 70\%$ (30 cặp).
      - *Khác thuật toán (Type-4):* $\text{Sim} < 50\%$ (120 cặp) — Sinh viên giải bằng 2 cách khác nhau (mảng vs đệ quy, sắp xếp vs hai con trỏ), code khác nhau nhưng cùng đạt AC.

Bảng 4: Kết quả kiểm thử các mô hình trên tập C/C++ CODER (400 cặp — Tỉ lệ 1:1)

Mô hình / Phiên bản	Ngưỡng	Đúng Trùng lặp	Đúng Không TL	F1-Score	Precision	Recall	Accuracy
M1 Chưa huấn luyện	0,01	200 / 200	0 / 200	66,67%	50,00%	**100,00%**	50,00%
M1 Đóng băng 12 tầng	0,01	199 / 200	0 / 200	66,44%	49,87%	99,50%	49,75%
M1 Fine-tuning toàn bộ	0,97	191 / 200	28 / 200	67,85%	52,62%	95,50%	54,75%
M2 Chưa huấn luyện	0,01	200 / 200	0 / 200	66,67%	50,00%	**100,00%**	50,00%
M2 Đóng băng 12 tầng	0,07	176 / 200	61 / 200	68,35%	55,87%	88,00%	59,25%
M2 Fine-tuning toàn bộ	0,78	182 / 200	50 / 200	68,42%	54,82%	91,00%	58,00%
M3 Chưa huấn luyện	0,47	200 / 200	1 / 200	66,78%	50,13%	**100,00%**	50,25%
M3 Fine-tuning toàn bộ	0,36	183 / 200	65 / 200	**70,66%**	**57,55%**	91,50%	**62,00%**
M4 Chưa huấn luyện	0,01	200 / 200	0 / 200	66,67%	50,00%	**100,00%**	50,00%
M4 Fine-tuning toàn bộ	0,01	200 / 200	0 / 200	66,67%	50,00%	**100,00%**	50,00%

Bảng 5: Số lượng mẫu nhận diện đúng trên từng nhóm C/C++

Mô hình / Phiên bản	Sao chép (Type-1/2/ST3)	Tương đồng vừa (MT3)	Khác thuật toán (Type-4)	Không trùng lặp (Khác bài)
M1 Chưa huấn luyện	50 / 50	30 / 30	120 / 120	0 / 200
M1 Đóng băng 12 tầng	50 / 50	30 / 30	119 / 120	0 / 200
M1 Fine-tuning toàn bộ	47 / 50	29 / 30	115 / 120	28 / 200
M2 Chưa huấn luyện	50 / 50	30 / 30	120 / 120	0 / 200
M2 Đóng băng 12 tầng	43 / 50	27 / 30	106 / 120	61 / 200
M2 Fine-tuning toàn bộ	46 / 50	25 / 30	111 / 120	50 / 200
M3 Chưa huấn luyện	50 / 50	30 / 30	120 / 120	1 / 200
M3 Fine-tuning toàn bộ	50 / 50	29 / 30	104 / 120	**65 / 200**
M4 Chưa huấn luyện	50 / 50	30 / 30	120 / 120	0 / 200
M4 Fine-tuning toàn bộ	50 / 50	30 / 30	120 / 120	0 / 200

Nhận xét kết quả kiểm thử C/C++:

- **M3 (ASTNN) đạt kết quả tốt nhất:** ASTNN đạt F1 cao nhất ($70,66\%$) và Accuracy ($62,00\%$). Nhờ cơ chế mã hóa chuỗi câu lệnh trừu tượng, ASTNN ít bị ảnh hưởng bởi các từ khóa khai báo chung của C++ so với Transformer.
- **Nhận diện tốt các bài khác thuật toán (Type-4):** Các mô hình sau khi huấn luyện (M1, M2, M3) đều nhận diện chính xác phần lớn các ca khác thuật toán nhưng cùng đạt AC ($104 - 115/120$ cặp), chứng minh mô hình học được ngữ nghĩa bài toán chứ không chỉ nhìn mặt chữ.
- **Ảnh hưởng của từ khóa C-style:** Vì mô hình được học trên Java, khi kiểm thử trên C++ các bài khác nhau vẫn có nhiều từ khóa chung (`#include`, `cin`, `cout`), khiến mô hình dễ đoán nhầm là trùng lặp nếu để ngưỡng thấp. Cần đặt ngưỡng cao để lọc chính xác.

6 Hạn chế hiện tại

- **Tỉ lệ đoán đúng cặp Không trùng lặp còn thấp:** Các mô hình đoán nhầm nhiều cặp khác bài toán thành trùng lặp (False Positive cao), đúng cao nhất mới đạt $65/200$ (M3).
- **Nhiễu khung bài tập (Boilerplate):** Code C/C++ của sinh viên khá ngắn và dùng chung nhiều đoạn khung (`#include`, `ios_base`, `cin`, `cout`), chiếm tỉ lệ token lớn khiến mô hình ngộ nhận là cùng thuật toán.
- **Mô hình đồ thị (M4):** CPG-GNN bị ảnh hưởng bởi macro và tiền xử lý C++ dẫn đến dự đoán thiên lệch toàn bộ về nhãn 1.

7 Kế hoạch tuần tới

- **Lọc sạch khung mã nguồn (Boilerplate Stripping):** Loại bỏ khai báo thư viện và I/O cơ bản, chỉ giữ lại thân hàm và logic cốt lõi để triệt tiêu trùng lặp giả.
- **Tối ưu M3 và M4:** Tinh giản các node rác trên cây AST (M3) và chuẩn hóa luồng điều khiển/dữ liệu trên đồ thị CPG (M4).

Tài liệu

[1] J. Svajlenko, J. F. Islam, I. Keivanloo, C. K. Roy, and M. M. Mia, "Towards a Big Data Curated Benchmark of Inter-Project Code Clones," in *2014 IEEE International Conference on Software Maintenance and Evolution (ICSME)*, 2014, pp. 476–480. DOI: https://doi.org/10.1109/ICSME.2014.77 (https://sci-hub.vn/10.1109/ICSME.2014.77).