Báo cáo kết quả tuần 25–31/10

Đề tài: Phát hiện trùng lặp mã nguồn đa ngôn ngữ (Java, C/C++)

Kichirou Đề tài nghiên cứu NLP / Semantic Code Clone Detection

Ngày 31 tháng 10 năm 2026

1 Tóm tắt công việc hoàn thành trong tuần

- Huấn luyện lại các mô hình CodeBERT, GraphCodeBERT, ASTNN, CPG-GNN sử dụng dataset BigCloneBench.
- Kiểm thử các mô hình sau khi huấn luyện.

2 Tập dữ liệu BigCloneBench (Java)

Nhằm chuyển dịch bài toán sang ngôn ngữ hướng đối tượng thực tế và chuẩn hóa theo thang đo quốc tế, dự án sử dụng bộ dữ liệu chuẩn **BigCloneBench** (thuộc benchmark CodeXGLUE của Google/Microsoft):

- **Nguồn gốc dữ liệu:** Trích xuất từ kho mã nguồn IJaDataset-2.0, gồm các hàm Java thuộc các hệ thống phần mềm thực tế với 43 chức năng mục tiêu (I/O tệp, mạng, cơ sở dữ liệu, xử lý chuỗi,...).
- **Cấu trúc mẫu dữ liệu:** Mỗi mẫu là một cặp hàm Java kèm nhãn nhị phân:
  - `id`: Mã định danh duy nhất của cặp đánh giá.
  - `id1`, `id2`: Mã định danh của hàm 1 và hàm 2.
  - `func1`, `func2`: Mã nguồn đầy đủ của 2 hàm Java.
  - `label`: 1 (Trùng lặp — Clone) hoặc 0 (Không trùng lặp — Non-clone).
- **Độ dài mã nguồn:** Trung bình $33,96$ dòng code (1.642 ký tự); dòng ngắn nhất: 5 dòng; dòng dài nhất: 371 dòng.

Bảng 1: Thống kê quy mô phân chia tập dữ liệu BigCloneBench

Tập dữ liệu	Số lượng cặp	Tỉ lệ Clone
Train	30.000	50% (15.000 clone : 15.000 non-clone)
Val	3.000	50% (1.500 clone : 1.500 non-clone)
Test	5.000	50% (2.500 clone : 2.500 non-clone)

3 Thông số cấu hình huấn luyện

Bảng 2 tổng hợp các thông số huấn luyện cốt lõi của 4 mô hình trên BigCloneBench.

Bảng 2: Bảng thông số huấn luyện của các mô hình

Thông số	M1 Freeze	M1 Full	M2 Freeze	M2 Full	M3	M4
Biểu diễn đầu vào	Chuỗi Token (≤ 256)	Chuỗi Token (≤ 256)	Chuỗi Token + DFG	Chuỗi Token + DFG	Cây cú pháp AST	Đồ thị CPG
Thuật toán tối ưu	AdamW	AdamW	AdamW	AdamW	Adam	AdamW
Tốc độ học (LR)	10^{-3}	2×10^{-5}	10^{-3}	2×10^{-5}	10^{-3}	5×10^{-4}
Kích thước Batch	64	64	64	64	32	32
Số lượng Epochs	3	5	3	5	5	5
Hàm mất mát	BCEWithLogits	BCEWithLogits	BCEWithLogits	BCEWithLogits	BCEWithLogits	BCEWithLogits

- **Chưa huấn luyện (Untrained / Zero-shot):** Sử dụng mô hình ngôn ngữ pre-trained nguyên bản từ Microsoft, trích xuất vector `[CLS]` và đo độ tương đồng Cosine, không qua huấn luyện trên tác vụ phát hiện bản sao.
- **Đóng băng Backbone (Freeze):** Đóng băng toàn bộ 12 tầng Transformer của backbone (giữ nguyên 100% tri thức tiền huấn luyện), chỉ huấn luyện tầng phân loại cặp MLP ($1,77$M tham số cần học), tránh hiện tượng quên tri thức ban đầu.
- **Huấn luyện toàn bộ (Full Fine-tuning):** Mở khóa và tinh chỉnh toàn bộ $126,4$M tham số (cả 12 tầng Transformer và MLP head) trên tập dữ liệu BigCloneBench.
- **Mô hình cây cú pháp và đồ thị (M3, M4):** M3 (ASTNN) mã hóa chuỗi câu lệnh AST bằng RvNN + Bi-GRU; M4 (CPG-GNN) tổng hợp đặc trưng nút và cạnh qua 3 tầng GAT trên đồ thị CPG.

4 Kết quả kiểm thử trên tập dữ liệu BigCloneBench (Java)

Bảng 3 tổng hợp kết quả đánh giá đối chứng toàn diện các phiên bản mô hình trên tập dữ liệu kiểm thử Java BigCloneBench.

Bảng 3: Kết quả kiểm thử đối chứng các phiên bản mô hình trên tập Java BigCloneBench

Mô hình / Phiên bản	Ngưỡng	F1-Score	Precision	Recall	Accuracy
M1 Chưa huấn luyện	0,99	29,18%	17,16%	97,50%	21,11%
M1 Freeze (Đóng băng 12 tầng)	0,46	54,26%	50,72%	58,33%	83,61%
M1 Full (Fine-tuning toàn bộ)	0,88	**90,21%**	87,12%	**93,53%**	97,24%
M2 Chưa huấn luyện	0,97	66,37%	71,84%	61,67%	89,58%
M2 Freeze (Đóng băng 12 tầng)	0,014	56,49%	52,11%	61,67%	84,17%
M2 Full (Fine-tuning toàn bộ)	0,94	**91,70%**	**92,39%**	91,03%	**97,76%**
M3 Chưa huấn luyện	0,91	32,83%	19,64%	100,00%	31,81%
M3 Full	0,52	25,54%	14,88%	90,00%	28,62%
M4 Chưa huấn luyện	0,10	28,57%	16,67%	100,00%	16,67%
M4 Full	0,70	42,98%	37,45%	50,44%	81,80%

5 Hạn chế hiện tại

- **Giới hạn kiến trúc của ASTNN (M3):** Mạng RvNN chỉ tối ưu cho các đoạn mã ngắn. Khi gặp cây cú pháp Java phức tạp, mô hình bị tiêu biến thông tin, dẫn tới F1 dừng ở 25,54%.

6 Kế hoạch tuần tới