Báo cáo kết quả tuần 25–31/10

Đề tài: Phát hiện trùng lặp mã nguồn đa ngôn ngữ (Java, C/C++)

Kichirou Đề tài nghiên cứu NLP / Semantic Code Clone Detection

Ngày 31 tháng 10 năm 2026

1 Kết quả tuần này

Trong tuần làm việc vừa qua, dự án đã hoàn thành các mục tiêu chuyển đổi, huấn luyện lại toàn bộ mô hình trên tập dữ liệu chuẩn mới và xây dựng hệ thống kiểm thử định tính mở rộng:

- **Chuyển đổi toàn diện sang dữ liệu BigCloneBench (Java):**
  - Tích hợp pipeline đọc, tiền xử lý và chia tập dữ liệu từ Hugging Face: `google/code_x_glue_cc_clone_detection_big_clone_bench`.
  - Trích xuất và lập chỉ mục bộ nhớ đệm cây cú pháp trừu tượng (**AST Cache**) cho toàn bộ 9.126 hàm Java đơn nhất thông qua `tree-sitter-java`.
  - Trích xuất cấu trúc đồ thị thuộc tính mã nguồn (**Joern CPG**) cho 9.122 hàm Java bằng công cụ phân tích tĩnh Joern (`javasrc2cpg`), trích xuất các cạnh AST, CFG (Control Flow Graph), CDG và DDG (Data Flow Graph).
- **Huấn luyện lại độc lập cả 4 mô hình cốt lõi trên BigCloneBench (GPU Tesla T4):**
  - **M1 (CodeBERT):** Transformer biểu diễn chuỗi token kết hợp phân loại cặp `[CLS] func1 [SEP] func2`.
  - **M2 (GraphCodeBERT):** Kết hợp chuỗi mã nguồn và đồ thị luồng dữ liệu (Data Flow Graph - DFG).
  - **M3 (ASTNN):** Mạng nơ-ron hồi quy theo khối câu lệnh trên cây cú pháp trừu tượng (RvNN).
  - **M4 (CPG-GNN):** Mạng nơ-ron đồ thị (GAT backbone 3 tầng, 4 heads) học trên biểu diễn Joern CPG.
  - **Tối ưu hóa FP16 Mixed Precision:** Áp dụng `torch.amp.autocast` trên GPU Tesla T4, rút ngắn thời gian huấn luyện từ 2,6 giờ/epoch xuống còn **15 phút/epoch** (tăng tốc độ hơn 8 lần).
- **Xây dựng và mở rộng 2 bộ kiểm thử định tính chuẩn hóa với tỉ lệ mất cân bằng 1:5:**
  - **Bộ kiểm thử Java** (`data/custom_suite_java/`): Thiết kế 15 bài toán giải thuật kinh điển (Sắp xếp, Đồ thị, Chuỗi, Cấu trúc dữ liệu OOP, Quy hoạch động, Số học) gồm **90 tệp mã nguồn Java**. Sinh **720 cặp kiểm thử** theo tỉ lệ chuẩn $1:5$ (120 cặp trùng lặp : 600 cặp không trùng lặp).
  - **Bộ kiểm thử C/C++** (`data/custom_suite/`): Xây dựng tương đương 15 bài toán giải thuật với **121 tệp mã nguồn C/C++**. Sinh **720 cặp kiểm thử** theo tỉ lệ chuẩn $1:5$ (120 cặp trùng lặp : 600 cặp không trùng lặp).
  - Bao phủ toàn diện 4 loại trùng lặp chuẩn (Type-1, Type-2, Type-3, Type-4 Semantic Clone) cùng 2 nhóm âm tính (cạm bẫy khung sườn/traps và các cặp liên bài toán/cross-problem).
- **Thực hiện đánh giá đa chiều trên các tập kiểm thử:**
  - Đánh giá định lượng trên 5.000 cặp tập Test chính thức của BigCloneBench.
  - Đánh giá định tính trên tập test Java (720 cặp) bằng các checkpoint vừa huấn luyện.
  - Đánh giá định tính trên tập test C/C++ (720 cặp) bằng các checkpoint POJ-104.
  - Thiết kế sẵn giao diện nạp dữ liệu để chuẩn bị đón nhận tập kiểm thử thứ 3 (**Tập Coder**) theo kế hoạch.

2 Kết quả huấn luyện 4 mô hình trên BigCloneBench

Bảng 1 tổng hợp kết quả huấn luyện và đánh giá chính thức của 4 mô hình trên tập kiểm tra chuẩn BigCloneBench (5.000 cặp mã nguồn Java) trên GPU Tesla T4 (FP16 Mixed Precision).
Nhận xét từ quá trình huấn luyện:

1. **GraphCodeBERT (M2) đạt hiệu năng cao nhất:** Với F1 đạt **91,70%** và Precision đạt **92,39%**, mô hình thể hiện ưu thế vượt trội khi được bổ trợ quan hệ ràng buộc biến qua đồ thị luồng dữ liệu (DFG).

Bảng 1: Bảng kết quả huấn luyện và đánh giá 4 mô hình trên tập Test BigCloneBench Java (5.000 cặp)

Mã	Mô hình	Phương pháp biểu diễn	F1-Score	Precision	Recall	Accuracy	ROC-AUC
M1	CodeBERT	Chuỗi mã nguồn (Transformer)	90,21%	87,12%	**93,53%**	97,24%	**0,9822**
M2	GraphCodeBERT	Chuỗi + Luồng dữ liệu (DFG)	**91,70%**	**92,39%**	91,03%	**97,76%**	0,9768
M3	ASTNN	Cây cú pháp trừu tượng (RvNN)	25,54%	14,88%	90,00%	28,62%	0,5996
M4	CPG-GNN	Đồ thị thuộc tính mã (Joern CPG)	42,98%	37,45%	50,44%	81,80%	0,7819

Đồ thị này giúp mô hình nhận diện chuẩn xác các biến thể ngữ nghĩa ngay cả khi tên biến và thứ tự câu lệnh bị xáo trộn.

2. **CodeBERT (M1) có độ bao phủ (Recall) và ROC-AUC tốt nhất:** Đạt Recall **93,53%** và ROC-AUC lên tới **0,9822**. Bộ tiền huấn luyện ngôn ngữ lớn giúp CodeBERT nhạy bén với các cấu trúc dòng lệnh và bắt được hầu hết các cặp clone.

3. **Sự tiến bộ của CPG-GNN (M4):** M4 đạt Accuracy 81,80% và ROC-AUC 0,7819. Qua 5 epoch huấn luyện, Val-F1 tăng đều từ 23,97% lên 43,91%. Việc sử dụng GAT backbone với 4 heads chú ý giúp mô hình trích lọc được thông tin cấu trúc liên kết cạnh CFG và CDG trong mã nguồn Java.

4. **Thách thức của ASTNN (M3):** Do mã nguồn Java trong BigCloneBench có kích thước khối lệnh lớn và số lượng statement types đa dạng (45 loại câu lệnh), biểu diễn cây thuần túy gặp hiện tượng phân tán thông tin qua các tầng RvNN, dẫn đến F1 dừng ở mức 25,54% trên tập test lớn.

3 Kết quả kiểm thử định tính trên các tập test (Tỉ lệ 1:5)

Nhằm đánh giá hành vi định tính của các mô hình khi đối mặt với tỉ lệ mất cân bằng dữ liệu thực tế (1 cặp clone : 5 cặp non-clone), 2 bộ kiểm thử độc lập gồm 720 cặp đã được thực hiện bằng các checkpoint tinh chỉnh chính thức.

3.1 Kết quả kiểm thử trên tập Java (720 cặp)

Tập kiểm thử gồm 90 tệp mã nguồn Java trải dài qua 15 bài toán giải thuật: Sắp xếp mảng, UCLN, BFS/DFS đồ thị, Xâu đối xứng, Danh sách liên kết OOP, Tìm kiếm nhị phân, Fibonacci, Số nguyên tố, Nhân ma trận, Anagram, Thuật toán Kadane, Trộn mảng đã sắp, Hàng đợi vòng, Hàm lũy thừa x^n, và Tiền tố chung dài nhất.

Bảng 2: Hiệu năng tổng thể của 4 mô hình trên tập kiểm thử Java (720 cặp — Tỉ lệ 1:5)

Mô hình	Ngưỡng	F1-Score	Precision	Recall	Accuracy	TP / FP / TN / FN
M1 (CodeBERT)	0,88	33,91%	20,49%	**98,33%**	36,11%	118 / 458 / 142 / 2
M2 (GraphCodeBERT)	0,94	**61,79%**	**45,78%**	95,00%	**80,42%**	114 / 135 / 465 / 6
M3 (ASTNN)	0,52	29,58%	18,33%	76,67%	39,17%	92 / 410 / 190 / 28
M4 (CPG-GNN)	0,70	0,00%	0,00%	0,00%	**83,33%**	0 / 0 / 600 / 120

Bảng 3: Độ chính xác chi tiết theo từng loại Clone và Cạm bẫy trên tập Java (%)

Phân loại kiểm thử	Số cặp	M1 (CodeBERT)	M2 (GraphCodeBERT)	M3 (ASTNN)	M4 (CPG-GNN)
Type-1 (Đổi tên, định dạng)	15	93,3%	**100,0%**	**100,0%**	0,0%
Type-2 (Đổi kiểu dữ liệu, wrapper)	30	**100,0%**	**100,0%**	86,7%	0,0%
Type-3 (Vòng lặp, luồng điều khiển)	30	96,7%	**96,7%**	80,0%	0,0%
Type-4 (Semantic Clones khác thuật toán)	45	**100,0%**	88,9%	60,0%	0,0%
Non-clone Khó (Cạm bẫy khung sườn)	75	9,3%	**48,0%**	13,3%	**100,0%**
Non-clone Khác bài (Cross-problem)	525	25,7%	**81,7%**	34,3%	**100,0%**

3.2 Kết quả kiểm thử trên tập C/C++ (720 cặp)

Tập kiểm thử gồm 121 tệp mã nguồn C/C++ được biên soạn tương đương 15 bài toán giải thuật, chấm bằng 4 checkpoint POJ-104 tại ngưỡng đóng băng.

Bảng 4: Hiệu năng tổng thể của 4 mô hình trên tập kiểm thử C/C++ (720 cặp — Tỉ lệ 1:5)

Mô hình	Ngưỡng	F1-Score	Precision	Recall	Accuracy	TP / FP / TN / FN
M1 (CodeBERT)	0,21	53,75%	38,95%	86,67%	75,14%	104 / 163 / 437 / 16
M2 (GraphCodeBERT)	0,66	**56,10%**	**40,75%**	**90,00%**	**76,53%**	108 / 157 / 443 / 12
M3 (ASTNN)	0,42	34,75%	21,63%	88,33%	44,72%	106 / 384 / 216 / 14
M4 (CPG-GNN)	0,47	28,57%	16,67%	**100,00%**	16,67%	120 / 600 / 0 / 0

Bảng 5: Độ chính xác chi tiết theo từng loại Clone và Cạm bẫy trên tập C/C++ (%)

Phân loại kiểm thử	Số cặp	M1 (CodeBERT)	M2 (GraphCodeBERT)	M3 (ASTNN)	M4 (CPG-GNN)
Type-1 (Đổi tên, định dạng)	15	**100,0%**	**100,0%**	**100,0%**	**100,0%**
Type-2 (Đổi kiểu, wrapper/vector)	30	**100,0%**	**100,0%**	**100,0%**	**100,0%**
Type-3 (Vòng lặp, luồng điều khiển)	30	93,3%	**100,0%**	**100,0%**	**100,0%**
Type-4 (Semantic Clones khác giải thuật)	45	68,9%	**73,3%**	68,9%	**100,0%**
Non-clone Khó (Cạm bẫy khung sườn)	75	**33,3%**	25,3%	21,3%	0,0%
Non-clone Khác bài (Cross-problem)	525	78,5%	**80,8%**	38,1%	0,0%

3.3 Kế hoạch mở rộng với tập Coder

Hệ thống kiểm thử đã được module hóa thông qua hai script chuẩn `scripts/build_custom_suite_*.py` và `scripts/score_custom_suite_*.py`. Ngay khi người dùng cung cấp tập dữ liệu thứ 3 (**Tập Coder**), tập này sẽ được đưa vào pipeline tự động để sinh ma trận nhầm lẫn và đối chiếu trực diện trên cả 3 tập kiểm thử (Java, C/C++, Coder).

3.4 So sánh hành vi đa ngôn ngữ của các mô hình

- **GraphCodeBERT (M2) là mô hình cân bằng và bền vững nhất:** Giữ vị trí số 1 trên cả hai ngôn ngữ (F1 đạt **61,79%** trên Java và **56,10%** trên C/C++ dưới tỉ lệ $1:5$). M2 loại bỏ được trên **80%** các ca khác bài toán và nhận diện được từ **73,3%** đến **88,9%** các ca trùng lặp ngữ nghĩa hoàn toàn khác thuật toán (Type-4).
- **CodeBERT (M1) có Recall vượt trội nhưng nhạy cảm với tỉ lệ mất cân bằng:** Đạt Recall cực cao (98,33% trên Java và 86,67% trên C/C++), bắt trọn vẹn các ca Type-4. Tuy nhiên, khi số lượng mẫu âm tính tăng gấp 5 lần, M1 gặp tỉ lệ dương tính giả cao trước các bẫy khung sườn (chỉ nhận diện đúng 9,3% cạm bẫy trên Java).
- **ASTNN (M3) phụ thuộc vào tính tương đồng hình thái cây:** Nhận diện hoàn hảo Type-1 và Type-2 (86–100%), nhưng đối với Type-4 (ví dụ BubbleSort vs QuickSort hay đệ quy vs lặp), độ chính xác giảm xuống 60–68% do cây cú pháp bị biến đổi cấu trúc phân nhánh sâu.

4 Hạn chế

Qua các đợt thực nghiệm tuần này, nhóm nghiên cứu ghi nhận một số hạn chế cốt lõi cần giải quyết:

1. **Hiện tượng dương tính giả dưới tỉ lệ dữ liệu thực tế ($1:5$):** Các tập kiểm thử thực tế có số lượng cặp không trùng lặp áp đảo. Các mô hình dựa trên chuỗi từ khóa (M1) có xu hướng dự đoán nhầm các bài toán khác nhau có chung bộ khung cú pháp (ví dụ: cùng dùng hai vòng lặp lồng nhau duyệt mảng nhưng một bài để sắp xếp, một bài để tìm phần tử trùng).

2. **Độ nhạy của ngưỡng quyết định khi chuyển dịch phân phối:** Ngưỡng tối ưu dò tìm trên tập validation cân bằng (tỉ lệ $1:1$) không còn tối ưu khi chuyển sang môi trường kiểm thử mất cân bằng ($1:5$). Cần một cơ chế chuẩn hóa ngưỡng phụ thuộc vào tỉ lệ prior của tập dữ liệu.

3. **Thời gian và tài nguyên trích xuất đồ thị CPG của Joern:** Công cụ Joern chạy trên nền JVM tiêu tốn thời gian phân tích cú pháp tĩnh đáng kể đối với các hàm lớn, gây khó khăn cho việc triển khai suy luận thời gian thực nếu không có cơ chế cache đồ thị offline sẵn sàng.

5 Kế hoạch tuần tới

Dựa trên kết quả và các hạn chế đã xác định, kế hoạch nghiên cứu tuần tới tập trung vào các nội dung sau:

- **Tiếp nhận và đánh giá trên tập dữ liệu Coder:** Tiến hành tiền xử lý, trích xuất đặc trưng và đưa tập dữ liệu Coder vào pipeline để hoàn thiện bảng so sánh 3 tập dữ liệu (Java, C/C++, Coder).
- **Hiệu chỉnh ngưỡng quyết định (Threshold Calibration):** Nghiên cứu cơ chế điều chỉnh ngưỡng theo tỉ lệ mất cân bằng dữ liệu (Cost-sensitive thresholding hoặc F_β-tuning) nhằm giảm thiểu triệt để số ca dương tính giả (FP) của M1 và M2 trước các cạm bẫy khung sườn.
- **Cập nhật và hoàn thiện Web Demo tương tác:** Nâng cấp giao diện Web Demo (FastAPI) hỗ trợ nạp đồng thời các checkpoint Java và C/C++, cho phép người dùng tùy chọn ngôn ngữ, nhập trực tiếp 2 đoạn mã và xem trực quan điểm tương đồng từ 4 kiến trúc biểu diễn.
- **Chuẩn bị tài liệu báo cáo tổng kết và slide thuyết trình đề tài.**