Báo cáo kết quả tuần 25–31/10

Đề tài: Phát hiện trùng lặp mã nguồn đa ngôn ngữ (Java, C/C++)

Kichirou Đề tài nghiên cứu NLP / Semantic Code Clone Detection

Ngày 31 tháng 10 năm 2026

1 Tóm tắt công việc hoàn thành trong tuần

- Huấn luyện lại các mô hình CodeBERT, GraphCodeBERT, ASTNN, CPG-GNN sử dụng dataset BigCloneBench.
- Kiểm thử các mô hình sau khi huấn luyện.

2 Tập dữ liệu BigCloneBench (Java)

Nhằm chuyển dịch bài toán sang ngôn ngữ hướng đối tượng thực tế và chuẩn hóa theo thang đo quốc tế, dự án sử dụng bộ dữ liệu chuẩn **BigCloneBench** (thuộc benchmark CodeXGLUE của Google/Microsoft):

- **Nguồn gốc dữ liệu:** Trích xuất từ kho mã nguồn IJaDataset-2.0, gồm các hàm Java thuộc các hệ thống phần mềm thực tế với 43 chức năng mục tiêu (I/O tệp, mạng, cơ sở dữ liệu, xử lý chuỗi,...).
- **Cấu trúc mẫu dữ liệu:** Mỗi mẫu là một cặp hàm Java kèm nhãn nhị phân:
  - `id`: Mã định danh duy nhất của cặp đánh giá.
  - `id1`, `id2`: Mã định danh của hàm 1 và hàm 2.
  - `func1`, `func2`: Mã nguồn đầy đủ của 2 hàm Java.
  - `label`: 1 (Trùng lặp — Clone) hoặc 0 (Không trùng lặp — Non-clone).
- **Độ dài mã nguồn:** Trung bình $33,96$ dòng code (1.642 ký tự); dòng ngắn nhất: 5 dòng; dòng dài nhất: 371 dòng.

Bảng 1: Thống kê quy mô phân chia tập dữ liệu BigCloneBench

Tập dữ liệu	Số lượng cặp	Tỉ lệ Clone
Train	30.000	50% (15.000 clone : 15.000 non-clone)
Val	3.000	50% (1.500 clone : 1.500 non-clone)
Test	5.000	50% (2.500 clone : 2.500 non-clone)

3 Thông số cấu hình huấn luyện

Bảng 2 tổng hợp các thông số huấn luyện cốt lõi của 4 mô hình trên BigCloneBench.

Bảng 2: Bảng thông số huấn luyện của các mô hình

Thông số	M1 Freeze	M1 Full	M2 Freeze	M2 Full	M3	M4
Biểu diễn đầu vào	Chuỗi Token (≤ 256)	Chuỗi Token (≤ 256)	Chuỗi Token + DFG	Chuỗi Token + DFG	Cây cú pháp AST	Đồ thị CPG
Thuật toán tối ưu	AdamW	AdamW	AdamW	AdamW	Adam	AdamW
Tốc độ học (LR)	10^{-3}	2×10^{-5}	10^{-3}	2×10^{-5}	10^{-3}	5×10^{-4}
Kích thước Batch	64	64	64	64	32	32
Số lượng Epochs	3	5	3	5	5	5
Hàm mất mát	BCEWithLogits	BCEWithLogits	BCEWithLogits	BCEWithLogits	BCEWithLogits	BCEWithLogits

4 Kết quả huấn luyện trên BigCloneBench (Java)

Kết quả đánh giá trên tập Test chính thức gồm 5.000 cặp Java của BigCloneBench được thể hiện ở Bảng 3.

Bảng 3: Kết quả đánh giá 4 mô hình trên tập Test BigCloneBench Java (5.000 cặp)

Mô hình	F1-Score	Precision	Recall	Accuracy	ROC-AUC
M1	90,21%	87,12%	**93,53%**	97,24%	**0,9822**
M2	**91,70%**	**92,39%**	91,03%	**97,76%**	0,9768
M3	25,54%	14,88%	90,00%	28,62%	0,5996
M4	42,98%	37,45%	50,44%	81,80%	0,7819

- **M2 (GraphCodeBERT) dẫn đầu:** Đạt F1 **91,70%** và Precision **92,39%**. Luồng dữ liệu DFG giúp mô hình bắt chính xác các quan hệ biến dù cú pháp thay đổi.
- **M1 (CodeBERT) có độ bao phủ tốt nhất:** Recall đạt **93,53%** và ROC-AUC đạt **0,9822**.
- **M3 (ASTNN) và M4 (CPG-GNN) gặp rào cản quy mô code:** ASTNN bị phân tán thông tin khi cây AST quá sâu (F1 dừng ở 25,54%); CPG-GNN đạt F1 42,98% và cần thêm dữ liệu đồ thị tinh chỉnh.

5 Kết quả kiểm thử thực tế trên 2 bộ test (Tỉ lệ 1:5)

5.1 Kết quả kiểm thử trên tập Java (720 cặp)

Bảng 4 và Bảng 5 thể hiện hiệu năng tổng thể và độ chính xác phân loại chi tiết trên 720 cặp Java.

Bảng 4: Hiệu năng đối chứng trên tập kiểm thử Java (720 cặp — Tỉ lệ 1:5)

Mô hình	Ngưỡng	F1-Score	Precision	Recall	Accuracy	TP / FP / TN / FN
M0 (MOSS)	1,00%	58,88%	**75,32%**	48,33%	**88,75%**	58 / 19 / 581 / 62
M1 Chưa huấn luyện	0,99	29,18%	17,16%	97,50%	21,11%	117 / 565 / 35 / 3
M1 Full	0,88	33,91%	20,49%	**98,33%**	36,11%	118 / 458 / 142 / 2
M1 Freeze	0,46	**54,26%**	50,72%	58,33%	83,61%	70 / 68 / 532 / 50
M2 Chưa huấn luyện	0,97	**66,37%**	71,84%	61,67%	89,58%	74 / 29 / 571 / 46
M2 Full	0,94	61,79%	45,78%	95,00%	80,42%	114 / 135 / 465 / 6
M2 Freeze	0,014	56,49%	52,11%	61,67%	84,17%	74 / 68 / 532 / 46
M3 Chưa huấn luyện	0,91	32,83%	19,64%	100,00%	31,81%	120 / 491 / 109 / 0
M3 Full	0,52	29,58%	18,33%	76,67%	39,17%	92 / 410 / 190 / 28
M4 Chưa huấn luyện	0,10	28,57%	16,67%	100,00%	16,67%	120 / 600 / 0 / 0
M4 Full	0,70	0,00%	0,00%	0,00%	83,33%	0 / 0 / 600 / 120

Bảng 5: Độ chính xác chi tiết theo từng loại Clone và Cạm bẫy trên tập Java (%)

Phân loại kiểm thử	Số cặp	M0 (MOSS)	M1	M2	M3	M4
Type-1 (Đổi tên, định dạng)	15	**100,0%**	93,3%	**100,0%**	**100,0%**	0,0%
Type-2 (Đổi kiểu dữ liệu, wrapper)	30	53,3%	**100,0%**	**100,0%**	86,7%	0,0%
Type-3 (Vòng lặp, luồng điều khiển)	30	73,3%	96,7%	**96,7%**	80,0%	0,0%
Type-4 (Semantic Clones khác giải thuật)	45	11,1%	**100,0%**	88,9%	60,0%	0,0%
Non-clone Khó (Cạm bẫy khung sườn)	75	74,7%	9,3%	48,0%	13,3%	**100,0%**
Non-clone Khác bài (Cross-problem)	525	**100,0%**	25,7%	81,7%	34,3%	**100,0%**

- **MOSS thất bại trước Type-4:** Link báo cáo trực tiếp từ Stanford: `http://moss.stanford.edu/results/5/7425885853330`. MOSS chỉ phát hiện được 11,1% (5/45 cặp) Type-4 và bị lừa 19 ca bởi cạm bẫy khung sườn. Trong khi đó, CodeBERT và GraphCodeBERT bắt được 88,9–100% Type-4.
- **Phiên bản Freeze cải thiện độ chính xác:** Đối với M1, F1 tăng từ 29,18% lên **54,26%**, Accuracy tăng từ 21,11% lên **83,61%**, giảm mạnh số ca báo động giả từ 565 xuống còn 68 ca.

5.2 Kết quả kiểm thử trên tập C/C++ (720 cặp - dùng mô hình train từ Java)

Đánh giá khả năng chuyển dịch ngôn ngữ (Cross-lingual Transfer) trên 720 cặp C/C++ khi sử dụng các mô hình đã huấn luyện từ Java (Bảng 6 và Bảng 7).

Bảng 6: Hiệu năng đối chứng trên tập C/C++ khi dùng mô hình huấn luyện từ Java (720 cặp — Tỉ lệ 1:5)

Mô hình	Ngưỡng	F1-Score	Precision	Recall	Accuracy	TP / FP / TN / FN
M0 (MOSS)	1,00%	52,63%	**71,43%**	41,67%	87,50%	50 / 20 / 580 / 70
M1 Chưa huấn luyện	0,99	30,03%	17,80%	95,83%	25,56%	115 / 531 / 69 / 5
M1 Full	0,88	31,29%	18,55%	**100,00%**	26,81%	120 / 527 / 73 / 0
M1 Freeze	0,60	**53,85%**	63,64%	46,67%	86,67%	56 / 32 / 568 / 64
M2 Chưa huấn luyện	0,97	**65,35%**	61,94%	69,17%	87,78%	83 / 51 / 549 / 37
M2 Full	0,94	52,76%	37,77%	87,50%	73,89%	105 / 173 / 427 / 15
M2 Freeze	0,20	52,13%	60,44%	45,83%	85,97%	55 / 36 / 564 / 65
M3 Chưa huấn luyện	0,99	42,97%	31,00%	70,00%	69,03%	84 / 187 / 413 / 36
M3 Full	0,52	30,03%	18,88%	73,33%	43,06%	88 / 378 / 222 / 32
M4 Chưa huấn luyện	0,10	28,57%	16,67%	100,00%	16,67%	120 / 600 / 0 / 0
M4 Full	0,70	0,00%	0,00%	0,00%	83,33%	0 / 0 / 600 / 120

Bảng 7: Độ chính xác chi tiết theo từng loại Clone và Cạm bẫy trên tập C/C++ khi dùng mô hình Java (%)

Phân loại kiểm thử	Số cặp	M0 (MOSS)	M1	M2	M3	M4
Type-1 (Đổi tên, định dạng)	15	**100,0%**	**100,0%**	**100,0%**	**100,0%**	0,0%
Type-2 (Đổi kiểu, wrapper/vector)	30	53,3%	**100,0%**	**100,0%**	86,7%	0,0%
Type-3 (Vòng lặp, luồng điều khiển)	30	60,0%	**100,0%**	96,7%	86,7%	0,0%
Type-4 (Semantic Clones khác giải thuật)	45	2,2%	**100,0%**	68,9%	46,7%	0,0%
Non-clone Khó (Cạm bẫy khung sườn)	75	73,3%	6,7%	36,0%	25,3%	**100,0%**
Non-clone Khác bài (Cross-problem)	525	**100,0%**	13,0%	76,2%	38,7%	**100,0%**

- **MOSS gần như mù hoàn toàn trước Type-4 C/C++:** Link Stanford: `http://moss.stanford.edu/results/6/8345752841300`. MOSS chỉ bắt được đúng 1 trong 45 cặp Type-4 (đạt 2,2%), trong khi CodeBERT bắt trọn 100% và GraphCodeBERT bắt 68,9%.
- **Khả năng chuyển dịch ngôn ngữ của Transformer:** CodeBERT và GraphCodeBERT dù chỉ huấn luyện bằng Java nhưng khi kiểm thử trên C/C++ vẫn giữ ROC-AUC trên 79,4–89,8%. Phiên bản Freeze giúp tăng Precision lên 60,4–63,6%.

6 Hạn chế hiện tại

- **Giới hạn kiến trúc của ASTNN (M3):** Mạng RvNN chỉ tối ưu cho các đoạn mã ngắn. Khi gặp cây cú pháp Java phức tạp, mô hình bị tiêu biến thông tin, dẫn tới F1 dừng ở 25,54%.

7 Kế hoạch tuần tới